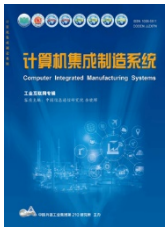

计算机集成制造系统
Computer Integrated Manufacturing Systems
ISSN 1006-5911,CN 11-5946/TP

《计算机集成制造系统》网络首发论文

题目：　基于新型多模态强化学习的机械臂运动规划方法
作者：　周福杰，胡祥涛，李子怡，韦治宏
DOI：　10.13196/j.cims.2024.0575
收稿日期：　2024-11-04
网络首发日期：　2025-07-23
引用格式：　周福杰，胡祥涛，李子怡，韦治宏．基于新型多模态强化学习的机械臂运动规划方法[J/OL]．计算机集成制造系统.
https://doi.org/10.13196/j.cims.2024.0575

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2025-07-23 10:06:09　　网络首发地址：https://link.cnki.net/urlid/11.5946.TP.20250723.0937.002

DOI:10.13196/j.cims.2024.0575

基于新型多模态强化学习的机械臂运动规划方法

周福杰，胡祥涛[+]，李子怡，韦治宏
（安徽大学 电气工程与自动化学院，安徽 合肥 230601）

摘 要：本文提出了一种新的多模态强化学习方法，旨在通过整合多模态信息来提高机械臂自主运动规划能力。该方法以近端策略优化(Proximal Policy Optimization，PPO)算法为基础框架，结合变分自编码器和高斯混合模型，构建了包含观测图像信息、机器人运动学信息的多模态表示网络，将状态学习和策略学习解耦，降低了模型训练复杂度。此外，基于 Mask R-CNN 设计了动作引导机制和新型密集奖励函数，减少了学习过程中的无效探索，加速了算法收敛。仿真实验结果表明，与常规的 PPO 算法相比，提出的方法展现出了显著的优势，证明了所设计的多模态表示网络、动作引导机制和密集奖励函数在提升算法性能方面的有益效果。

关键词：多模态强化学习；机械臂；运动规划；变分自编码器；高斯混合模型
中图分类号：TP242.2　　**文献标识码：**A

Motion planning method for robotic arms based on novel multimodal reinforcement learning

ZHOU Fujie，*HU Xiangtao*[+]，*LI Ziyi*，*WEI Zhihong*
(School of Electrical Engineering and Automation, Anhui University, Hefei 230601, China)

Abstract：This paper proposes a novel multi-modal reinforcement learning approach, aiming to enhance the autonomous motion planning capability of manipulators by integrating multi-modal information. Taking the classic Proximal Policy Optimization (PPO) algorithm as the basic framework, the approach combines Variational Autoencoder (VAE) and Gaussian Mixture Model (GMM) to construct a multi-modal representation network that integrates observation image information and robot kinematic information. This network decouples state learning from policy learning, effectively reducing the model training complexity. Additionally, an action guidance module and a dense reward function are designed based on Mask R-CNN, which minimize invalid exploration in the learning process and accelerate algorithm convergence. Experimental results show that compared with the conventional PPO algorithm, the proposed method demonstrates superior motion planning capabilities. This verifies the beneficial effects of the multi-modal representation network, action guidance mechanism, and dense reward function in enhancing algorithm performance.

Keywords：multimodal reinforcement learning; robotic arm; motion planning; variational auto-encoder; Gaussian mixture model

收稿日期：2024-11-04；修订日期：2025-07-14。Received 04 Nov. 2024;accepted 14 July 2025.
基金项目：国家自然科学基金资助项目（52175210）；江淮前沿技术中心追梦基金资助项目（2023-ZM01Z009）。

0 引言

近年来，机器人技术已经取得了长足进步，广泛应用于制造业、农业、医疗等领域，促进了社会发展和行业变革[1-3]。然而，当前机器人大多服务于固定场景按照既定程序执行固定任务，在非结构化场景中，机器人仍然表现较差，离机器人自主作业或服务还有很长的距离。面对非结构化环境，机械臂的运动规划能力成为了决定其能否高效、精准地完成各种复杂任务的关键因素[4,5]。机械臂运动规划旨在代替人工示教，实现从起点到终点的自主地路径规划，且能避开所有障碍物[6]。

机械臂的运动规划一直是国内外研究热点。随着深度强化学习（Deep Reinforcement Learning, DRL）的兴起，为非结构化环境下机械臂的运动规划提供了新的思路和方法[7]。DRL 结合了深度学习的强大感知能力和强化学习的智能决策能力，使得机械臂能够在复杂的环境中通过不断试错和学习，找到最优的规划策略。然而，DRL 在保全环境信息完整性的同时也带来高维观测的问题，使得策略拟合变得更为复杂，奖励变的更为稀疏[8]。学习优秀的状态表示并设计有效的奖励函数是 DRL 取得成功的关键[9,10]。为此，很多学者建议利用自监督学习预训练状态表示模型，将高维观测空间转化为低维特征空间，降低算法处理复杂度。Kim 等人[11]通过变分自编码器从观测图像中提取环境的潜在特征，并通过预训练模型获得演示数据的特定表示，实现机械臂的安全快速学习。Jonschkowski 和 Brock[12]设计了状态表示学习网络，提取任务相关特征参量作为状态表示，提高强化学习的鲁棒性。奖励函数的设计在强化学习中也起着重要作用，决定了算法收敛性。Zhang 等[13]、James 和 Johns[14]、Zeng 等[15]根据笛卡尔空间中的物体位置、速度和加速度等物理参数设计密集奖励函数。Franceschetti 等[16]根据真实状态与状态表示网络预测状态之间的偏差来定义奖励函数，应用好奇心驱动的探索机制鼓励智能体与环境进行交互。Gang 等人[17]根据姿态、步幅和学习阶段提出了三种密集奖励函数，提高了运动规划的效率和稳定性。笔者团队在文献[18]中提出了任务导向强化学习框架，使用四个相机获取环境多视角观测图像，经 Mask R-CNN 检测，提取各视图中感兴趣物体的边界框作为任务特征，定义兴趣状态与兴趣奖励，用于复杂环境下机械臂运动控制，实验结果表明该框架具有较好的目标迁移性和抗干扰性能。

尽管 DRL 在机械臂运动控制中取得了显著进展，但仍然面临着状态表示不完整、高维数据学习效率低和奖励函数设计困难等挑战，限制了机械臂对作业环境和自身状态的全面感知与理解[19-21]。为了克服这一局限，本文提出了一种名为 M3RRL 的新型多模态强化学习方法。M3RRL 方法以 PPO 算法为基础框架，结合变分自编码器（Variational auto-encoder，VAE）和高斯混合模型（Gaussian Mixture Model，GMM）技术，旨在通过整合多模态信息来提高机械臂的感知与决策能力，实现机械臂自主运动规划。

1 相关算法基础

1.1 PPO 概述

PPO 是 OpenAI 于 2017 年提出的一种强化学习算法，因其广泛的适用性而备受赞誉。PPO 算法由策略梯

度（Policy Gradient, PG）算法改进而来，解决了 PG 算法对更新步长敏感性问题，以及 on-policy 方式带来的数据之间强相关性、样本利用率低、训练不稳定等问题。PPO 算法主要思想是在每一步中通过最大限度地利用已有数据对策略进行更新，同时尽量避免策略产生较大变化，可以实现更加稳定和高效的训练过程。

近端策略优化裁剪（PPO-Clip）是 PPO 算法的一个变种，使用了裁剪函数 Clip 限制每次更新的幅度。PPO-Clip 算法的损失函数 L^{Clip} 定义如下：

$$L^{Clip}(\theta)=\mathrm{E}_t\left(\min\left(r_t(\theta)\hat{A}_t,\mathrm{Clip}\left(r_t(\theta),1-\varepsilon,1+\varepsilon\right)\hat{A}_t\right)\right) \tag{1}$$

其中：θ 为当前策略网络参数；E_t 表示对时间步 t 的期望；$\hat{A}_t$ 为优势函数的估计，表示在状态 s_t 下采取动作 a_t 相对于基准策略的优势；ε 为 Clip 函数的超参数；$r_t(\theta)$ 为新旧策略的概率比值。

因为 PPO-Clip 算法在训练过程中能够将策略控制在一定的变化范围内，实现更加稳定和高效的学习，同时在高维、连续控制方面有较好的表现，因而在机械臂运动规划中被广泛应用。本文也采用了 PPO-Clip 版本进行机器人运动规划，以下简称 PPO。

1.2 VAE 概述

VAE[11]是一种生成模型，通过变分推断将自编码器的确定性映射扩展为概率分布。与传统自编码器相比，VAE 不仅学习数据的压缩表示（编码），还显式建模了潜在空间的概率分布，从而支持生成新样本。

VAE 由编码器和解码器组成。编码器的作用是将输入数据 $\boldsymbol{x}$ 压缩至一个潜在空间，输出高斯分布参数 $\boldsymbol{\mu}$ 和 $\log\boldsymbol{\sigma}^2$。然后借助重参数化技巧，如式（2）所示，从该高斯分布中采样潜在变量 $\boldsymbol{z}$：

$$\boldsymbol{z}=\boldsymbol{\mu}+\boldsymbol{\sigma}\odot\epsilon \tag{2}$$

其中，ϵ 服从标准正态分布。

解码器采用与编码器对称的网络结构，将采样得到的潜在变量 $\boldsymbol{z}$ 映射回原始数据空间，最终输出数据的重建样本。

1.3 GMM 概述

GMM 是一种概率生成模型，其核心思想是将潜在空间的分布建模为混合高斯分布，而非单一高斯分布[22]。对于一组数据集 $\{\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_n\}$，令其服从混合高斯分布，则 GMM 的概率密度函数 p 可表示为：

$$p\left(\boldsymbol{x}\middle|\boldsymbol{\vartheta}\right)=\sum_{k=1}^{K}\pi_k\cdot\mathcal{N}\left(\boldsymbol{x}\middle|\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k\right) \tag{3}$$

式中，$\boldsymbol{\vartheta}$ 为 GMM 参数，π_k 为第 k 个高斯分布的权重参数，$\boldsymbol{\mu}_k$ 是均值向量，$\boldsymbol{\Sigma}_k$ 是协方差矩阵，$\mathcal{N}(\boldsymbol{x}|\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k)$ 表示第 k 个高斯分布。

在多模态学习中，GMM 可将高维特征转换为概率分布参数，便于后续的特征融合和生成建模。文献[23]利用 GMM 构建了机械臂末端位置、速度和接触力的映射概率模型。本文拟将 GMM 和 VAE 结合进行机械臂

多模态混合建模，即在 VAE 模型中，用 GMM 替代标准正态分布。

2 提出的 M3RRL 方法

2.1 多模态表示网络设计

本文将末端视野的图像、机械臂运动学信息作为输入数据，基于 GMM-VAE 技术提出一种多模态表示网络。通过学习不同模态数据的多样化特征，更全面的描述机械臂与环境交互细节，提升机械臂对作业环境和自身状态的全面感知与理解。多模态表示网络由三部分组成：编码器（Encoder）、融合（Fusion）和解码器（Decoder），在融合部分使用了 GMM 模型，如图 1 所示（图中符号见后文描述）。

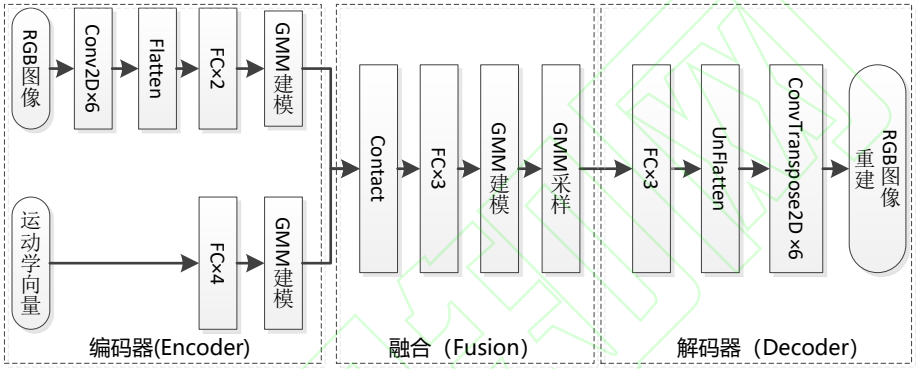

图 1 多模态表示网络结构框图

编码器将两种类型数据编码，编码处理方法如下：

(1) 末端观测图像

安装在机械臂末端相机获取环境 RGB 图像。首先通过六层二维卷积（Conv2D）逐步提取图像语义特征，接着将卷积输出的三维特征图展平（Flatten）成特征向量，再通过两层全连接层（FC）进行降维映射。最后，采用 K 个高斯分布混合的 GMM 对降维后的特征向量进行建模（通常 K=3~5，本文后续实验取 3）。

(2) 机械臂运动学信息

由机械臂关节角、关节速度、末端位姿和速度等组成的多维向量，采用 4 层全连接层进行升维映射，输出机械臂运动学特征向量。同理，采用 K 个高斯分布混合的 GMM 对机械臂运动学特征向量进行建模。

融合部分，首先通过拼接（Contact）将两类 GMM 参数化后的特征向量串联，然后通过 3 层全连接层映射，再通过 GMM 对特征向量整体建模，融合特征间的非线性关系，以便于捕捉多模态数据之间的复杂关系。

解码器按照式（2）从 GMM 中采样，并经过三层全连接层进行升维，然后进行逆展平（Unflatten），再通过六层反卷积层（ConvTranspose2D）重建图像。

多模态表示网络通过最小化重建损失进行迭代更新，确保多模态数据特征及关联关系被有效学习。重建损失函数定义如下：

$$L_{recon} = \frac{1}{N}\sum_{i=1}^{N}\left(I_i - \hat{I}_i\right)^2 \tag{4}$$

其中，L_{recon} 表示重建损失，N 表示样本数，I 表示原始的观测图像，$\hat{I}$ 表示重建后的图像。

Encoder 与 Decoder 采用 Skip Connection 连接。当多模态表示网络预训练完成后，把解码器断开，使用融合后的 GMM 输出作为强化学习的状态表示。

2.2 多模态强化学习模型

基于多模态表示网络，构建了多模态强化学习模型（Multi Modal Reinforcement Learning based on Mask R-CNN，M3RRL）。该模型采用 PPO 强化学习框架，以多模态表示网络的输出为 PPO 的状态表示，学习运动规划策略。模型结构如图 2 所示，图中观测由末端观测图像 I_t、机械臂本体运动学信息 P_t 组成，图中其他符号见后文描述。

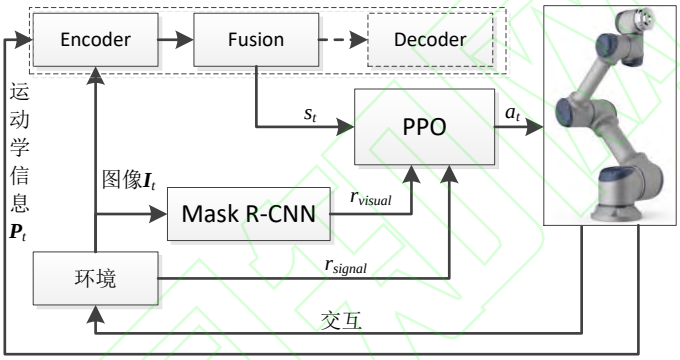

图 2 多模态强化学习模型结构框图

2.2.1 智能体状态与动作设置

将 $\{I_t, P_t\}$ 作为多模态网络的输入，从多模态网络的融合层获取特征向量 $\boldsymbol{z}$ 作为智能体 t 时刻状态 $\boldsymbol{s}_t$。t 时刻的动作 $\boldsymbol{a}_t$ 定义为机械臂末端位置增量 $\Delta\boldsymbol{\alpha}$。

2.2.2 动作引导机制

为了减少强化学习在学习过程中的无效动作，需对机械臂末端位置增量进行限制，所以，本文设计了动作引导机制。当末端相机捕捉到目标图像后，通过分析末端图像给出合理的动作界限，约束 PPO 动作 $\boldsymbol{a}_t$，以确保动作方向的有效性。

如图 3 所示，根据末端相机捕获的图像，采用 Mask R-CNN 获取目标相对位置信息。图中，红色框为目标检测框，黄色五角星为目标特征，黑色箭头为图像中心到目标检测框中心的方向矢量，方向矢量的长度为 L_{off}，方向矢量与图像水平轴之间的夹角为 ϕ。

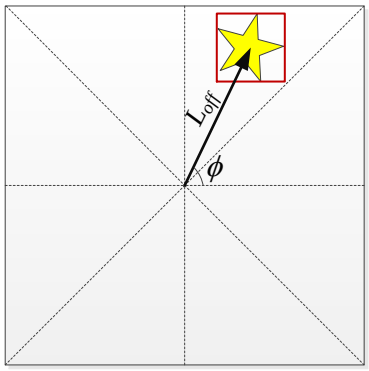

图 3 末端图像检测示意图

显然，希望机器人末端能够朝着目标检测框中心点方向移动。令相机坐标系为 O_C-$X_CY_CZ_C$，相平面为 Y_CZ_C 平面。令 Z_C 方向步长界限为常数 z_{Cbound}（本文取值为 1cm），X_C 和 Y_C 方向上的步长界限 x_{Cbound} 和 y_{Cbound} 按下式进行设置：

$$\begin{cases} x_{Cbound} = \kappa L_{off} \cos\phi \\ y_{Cbound} = \kappa L_{off} \sin\phi \end{cases} \tag{5}$$

式中，κ 为比例常数（本文取值为$\sqrt{2}/h$，h 是图像高度尺寸，单位 cm）。

令相机坐标系与机械臂末端坐标系一致，则可通过运动学逆解，将$[x_{Cbound}, y_{Cbound}, z_{Cbound}]$转换为关节步长界限 $\boldsymbol{\alpha}_{bound}$。按照此界限，对 PPO 输出的动作进行引导。动作引导机制采用 Clip 算子，经引导后，智能体执行的动作如式(8)所示：

$$a_t = \begin{cases} \mathrm{Clip}\left(\Delta\boldsymbol{\alpha}, \boldsymbol{\alpha}_{bound}\right), & \mathrm{flag} = 1 \\ \Delta\boldsymbol{\alpha}, & \mathrm{flag} = 0 \end{cases} \tag{6}$$

式中，flag 是布尔变量，当 flag=1 时表示检测到目标，反之为未检测到目标。

2.2.3 奖励函数设置

为了克服稀疏奖励带来的不利影响，本文提出一种新的密集奖励函数，由两部分组成：视觉奖励 r_{visual} 以及由环境产生的信号奖励 r_{signal}，如下式所示：

$$r = r_{visual} + r_{signal} \tag{7}$$

本文引入目标检测算法 Mask R-CNN，来构建视觉奖励。其基本思想是：如果机械臂通过末端相机观测到了目标，就给予正奖励，因为只有看到目标，才能引导机械臂去朝目标方向运动；如果看不到目标就给予负奖励；此外，如果目标在图像中占比越来越大、越来越靠近图像的中心，表明机械臂离目标越来越近，给予的奖励也越来越大。因此，视觉奖励 r_{visual} 定义如下：

$$r_{visual} = \begin{cases} ratio - \sqrt{2}L_{off}/h, & \mathrm{flag} = 1 \\ -l, & \mathrm{flag} = 0 \end{cases} \tag{8}$$

其中，l 是惩戒参数（本文取值 5）；h 是图像高度尺寸；$ratio$ 是目标检测框在图像中面积占比。

信号奖励 r_{signal} 为机械臂强化学习基础奖励，按照经验取值进行定义：

$$r_{signal}=\begin{cases}10, & if\ \text{successful}\\ -5, & if\ \text{collision}\\ -5, & if\ \text{out workspace}\\ 0, & \text{other}\end{cases} \tag{9}$$

3 测试与分析

为检验所提出的 M3RRL 算法有效性，本文在仿真环境里开展了测试分析。首先预训练多模态表示网络，然后进行 M3RRL 训练学习，并基于经典的 PPO 算法开展消融实验对比分析，最后进行运动规划测试实验。

3.1 试验环境设置

本文以线缆连接器机械臂辅助插拔为试验对象，验证机械臂自主接近目标的能力。即，在强化学习算法驱动下，机械臂末端能够准确到达线缆连接器位置，为后续的插拔作业奠定基础。线缆连接器的安装面一般都位于电子设备的背面或侧面，安装空间狭小，要实现线缆连接器插拔，至少需要 4 个自由度的机械臂。因此，本项目采用四自由度机械臂进行测试，包括 3 个位置自由度和 1 个工具方位自由度，如图 4 所示。本文在 Pybullet 中搭建了仿真环境，仿真环境中包括机械臂和安装面板，面板上有一个线缆连接器（图中黑色对象），即本文所设置运动规划目标位置，如图 5 所示。

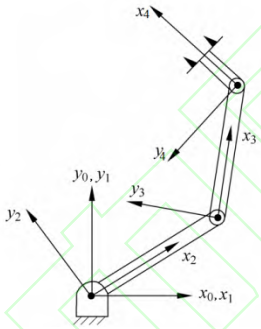

图 4 机械臂示意图

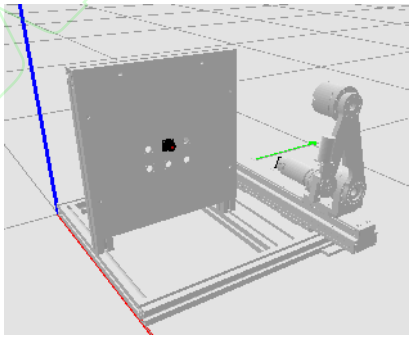
图 5 机械臂辅助插拔仿真模型

实验中，虚拟相机设定在机械臂的末端，用于获取环境图像；各关节编码器用于获取当前关节角度和关节速度。由于仿真环境下，未考虑机器人运动误差，故末端位置和速度由机器人正运动学获取。实验在线缆连接器的中心处设置虚拟目标点，将是否接触到虚拟目标点作为接近成功的标志。同时，实验将机械臂的运动空间限定在(0.36m, 0.05m, 0.1m)至(0.6mm, 0.45m, 0.4m)区间范围内，当机械臂末端超出该区域范围则回合结束，进入下一轮的训练。另外，本文采用 Mask R-CNN 进行目标检测，Mask R-CNN 训练数据集来源于虚拟相机在仿真环境里采集的图像。由于本文目标检测任务比较简单，所以 Mask R-CNN 训练过程这里不再赘叙。

3.2 多模态表示网络预训练

为了训练多模态表示网络，利用 3.1 节搭建的仿真环境进行样本收集。在限定的工作空间内，随机设定起始点和目标点，按照常规的轨迹规划方法生成机械臂运动轨迹，并在仿真环境里进行模拟运行。共收集了 1000

条轨迹数据，每条轨迹包含 50 个位点，每个位点的数据由$[I_t, P_t]$ 组成，数据类型与维度如表 1 所示。

表 1　多模态网络预训练数据

数据类型		数据维度
机器人运动学信息	关节位移	1×4
	关节速度	1×4
	末端位置	1×3
	末端速度	1×3
末端视角图像		128×128×3

为了构建高效且稳定的多模态表示网络，进行了长达 45000 个 epoch 的严格训练。图 6 展示了重建损失随 epoch 变化的曲线，图中横坐标为 epochs，纵坐标为总损失 L_{recon} 。从图中可以清晰地看到，随着训练的进行，重建损失迅速下降，并在较短的 epoch 数内实现了收敛。而且，收敛后的重建损失稳定在(0，0.05)波动范围内，表明了多模态表示网络具有了较好的稳定性。在 45000 个 epoch 训练结束后，冻结网络参数，用于后续多模态强化学习。

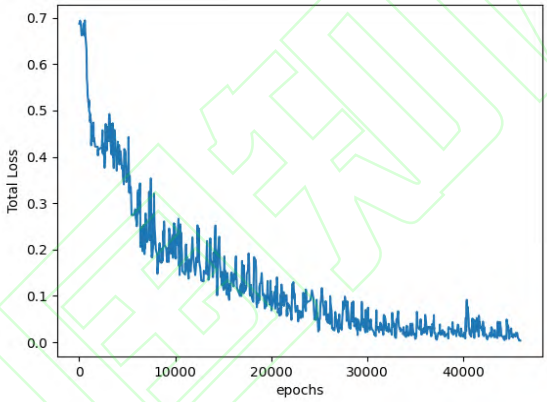

图 6 多模态网络损失变化曲线

3.3 消融对比实验分析

本节对提出的 M3RRL 算法进行仿真实验，训练机械臂学习运动规划策略。并与 PPO 算法、在 PPO 基础上增强的 MRRL（Mask R-CNN based Reinforcement Learning）算法进行消融实验对比。具体而言，以 PPO 算法作为基准，直接利用观测图像和机械臂的本体信息来构建状态表示，并利用式（9）所示的信号奖励函数指导训练过程。MRRL 算法是在 PPO 算法的基础上，引入了本文创新设计的动作引导模块和式（7）所示的奖励函数进行训练。为了直观展现各算法在训练过程中奖励曲线的动态变化，将所有算法的奖励值统一缩放至[-20,10]的范围内进行比较。实验总共涵盖了 10000 幕的训练，每一幕中机械臂的初始位置均在工作空间内随机设定，以确保实验的广泛性和公平性。

训练过程的成功率（Success Rate）和平均奖励（Mean Reward）随幕数（Episode）的变化曲线如图 7 所示。从图中可见：

（1）PPO 算法测试结果

在 PPO 算法的仿真实验中，随着训练幕数的逐渐增加，每回合的平均奖励呈现出总体上升的趋势。同时，成功率也伴随着训练的进行而稳步提高，在 9200 幕时，成功率已经达到了 90%的显著水平。然而，直至 10000 幕的训练结束，PPO 算法的成功率并未收敛至一个狭窄的范围内，这表明其仍存在进一步优化的空间。

（2）MRRL 算法测试结果

相较于 PPO 算法，MRRL 算法在仿真实验中展现出了更为出色的性能。随着训练幕数的增加，每回合的平均奖励值在前 3500 幕内实现了快速增长，并在随后的训练过程中稳定在一个微小的波动区间内。同时，成功率也在前 3200 幕内迅速攀升至 90%，并在之后的训练中稳定在 98%的高水平，且波动范围极小。这一显著的收敛效率和成功率提升，充分验证了本文设计的动作引导模块和奖励函数的有效性，它们共同促进了算法性能提升。

（3）M3RRL 算法测试结果

在 M3RRL 算法的仿真实验中，观察到了更加令人瞩目的性能表现。平均奖励值在 2000 幕内就实现了快速增长，并迅速稳定在一个极小的波动范围内。同时，在 1800 幕内，成功率也迅速攀升至 90%，并持续增长至 98%。与 MRRL 算法相比，M3RRL 算法的效率提升了约 1.5 倍。这一结果表明，相较于 MRRL 算法，M3RRL 算法在学习效率和稳定性上实现了进一步提升。这主要归功于本文所提出的多模态表示网络，进一步增强了算法的收敛性能和成功率。

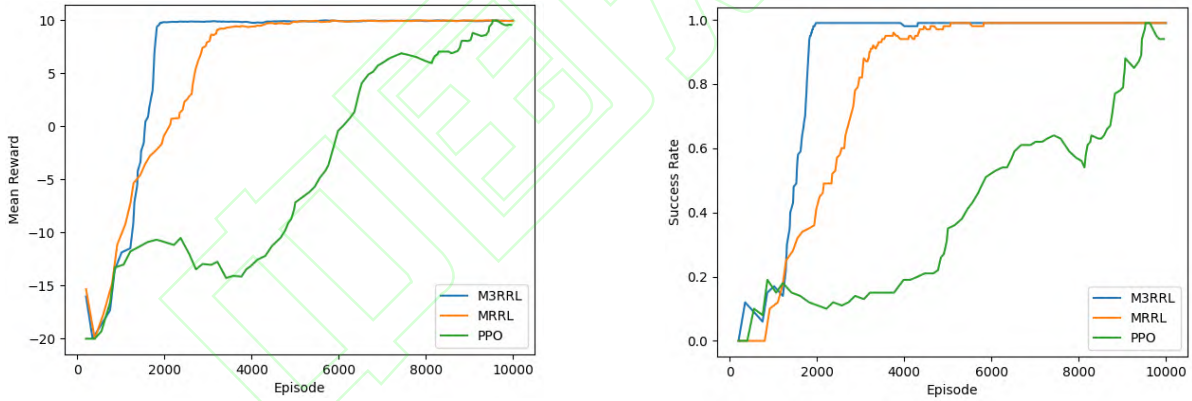

(a)平均奖励变化曲线　　(b) 成功率变化曲线

图 7 各算法训练结果

3.4 运动规划测试分析

利用上节已经训练完成的算法，在虚拟仿真环境中进行运动规划测试。统一设定了机械臂末端起点位置为(0.495m, 0.369m, 0.221m)，目标点位置为(0.365m, 0.200m, 0.280m)。

图 8 展示了各算法路径规划结果。图中，蓝色三角形代表了测试的起始点，绿色三角形则标记了目标点。红色、绿色、蓝色轨迹分别对应 M3RRL 算法、MRRL 算法以及 PPO 算法的规划结果。可以直观地看到：

（1）蓝色轨迹具有明显的折线和突变特征，表明 PPO 算法在寻找最优运动轨迹方面存在一定的局限性，未能实现路径的最优化。

（2）绿色轨迹起始段较为平滑，但在接近目标点时，轨迹出现了细微波折，表明 MMRL 算法在运动规划方面还有进一步优化空间。

（3）而红色轨迹在路径长度、平滑度以及与目标点的接近程度等方面都展现出了明显的优势，几乎呈现出完美的光滑曲线特征，没有出现明显的波折或突变。

测试结果表明了 M3RRL 算法具有卓越的运动规划能力，也进一步凸显了本文所提出的多模态表示网络、动作引导机制和密集奖励函数在提升算法性能方面的有益效果。

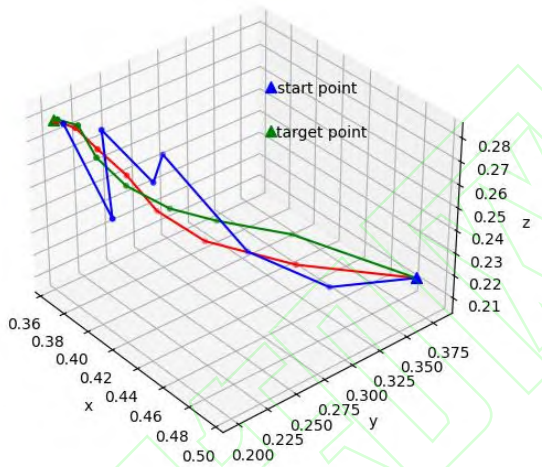

图 8 各算法运动规划测试结果

4 结束语

针对深度强化学习在复杂环境下面临的状态表示不完整、高维观测学习效率低和奖励函数设计困难等挑战，本文提出了一种名为 M3RRL 的多模态强化学习方法，旨在通过整合多模态信息来提高机械臂自主运动规划能力。M3RRL 以 PPO 算法为学习框架，结合 GMM-VAE 设计了包含环境观测图像和机械臂运动学信息的多模态表示网络，将状态学习和策略学习解耦，降低了学习难度。此外，引入 Mask R-CNN 目标检测算法，设计了一种新颖的密集奖励函数和动作引导机制，有效减少了学习过程无效探索，提高了学习效率。为验证算法性能，在 Pybullet 中搭建了四自由度机械臂仿真环境模型，开展了消融对比实验和运动规划测试实验。实验结果表明，本文所提出的多模态表示网络、动作引导机制和密集奖励函数在提升算法性能方面的有益效果，与常规 PPO 算法相比，M3RRL 展现出了优秀的运动规划能力。

深度强化学习作为一个复杂的研究课题，本文虽取得了初步进展，但仍存在两方面局限性：其一，实验环境设计较为基础，仅验证了简单场景下运动规划性能，尚未涉及静态障碍物、动态障碍物、多目标、遮挡目标等高难度复杂环境测试；其二，多模态表示网络架构仍有待优化，当前模型对传感器数据的特征提取与整合方式较为简易，未能充分挖掘视觉、运动学等多源数据的协同价值。未来，我们将持续深化 M3RRL 算法的架构与参数，提升其在复杂场景下的适应性与鲁棒性。

参考文献：

[1] CHEN Yujiao, ZENG Shiyu, HE Hongjie, et al. Research and implementation of digital twin system for industrial robot palletizing[J]. Computer Integrated Manufacturing Systems,2023,29(06):1930-1940.[陈玉娇,曾诗雨,和红杰,等.工业机器人码垛数字孪生系统的研究与实现[J].计算机集成制造系统,2023,29(06):1930-1940.]

[2] LIU Shihao, WANG Fei, LIN Mao, et al. Analysis and test of the kinematics characteristics of the robotic arm for a mango harvesting vehicle[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(1): 58-67.[刘世豪,王菲,林茂,等.芒果采收车机械臂运动特性分析及试验[J].农业工程学报,2024,40(01):58-67.]

[3] WANG Ke, ZHANG Hui, CAO Yihong, et al. Intelligent robots and key technologies for pharmaceutical production[J]. Computer Integrated Manufacturing Systems, 2022,28(07):1981-1995.[王可,张辉,曹意宏,等.面向医药生产的智能机器人及其关键技术研究综述[J].计算机集成制造系统,2022,28(07):1981-1995.]

[4] CAO Jinqi, HAN Xuesong. Review of Research Methods for Industrial Robot Trajectory Planning[J]. Information and Control,2024,53(04):471-486+498.[曹锦旗,韩雪松.工业机器人轨迹规划的研究方法综述[J].信息与控制,2024,53(04):471-486+498.]

[5] CAO Yi, GUO Yinhui, LI Lei, et al. Deep Reinforcement Learning-based Trajectory Planning for Manipulator Obstacle Avoidance[J]. Journal of Mechanical Transmission,2023,47(12):40-46+96.[曹毅,郭银辉,李磊,等.基于深度强化学习的机械臂避障轨迹规划研究[J].机械传动,2023,47(12):40-46+96.]

[6] ZHOU Dongxu. Research on Motion Planning Method of Robotic Arm Based on Deep Reinforcement Learning[D]. Beijing: China University of Mining and Technology, 2021. [周东旭. 基于深度强化学习的机械臂运动规划方法研究[D]. 北京：中国矿业大学, 2021.]

[7] XIE Zhengtai, FAN Jialiang, LIU Mei, et al. Learning and Control of Robots Based on Neural Networks: Review and Outlook[J]. Information and Control, 2023,52(01):37-58.[谢正泰,樊佳亮,刘梅,等.基于神经网络的机器人学习与控制：回顾与展望[J]. 信息与控制, 2023, 52(01): 37-58.]

[8] ZHAO Tingting, SUN Wei, CHEN Yarui, et al. Review of Deep Reinforcement Learning in Latent Space[J]. Journal of Frontiers of Computer Science and Technology,2023,17(09):2047-2074.[赵婷婷,孙威,陈亚瑞,等.潜在空间中深度强化学习方法研究综述[J].计算机科学与探索, 2023, 17(09): 2047-2074.]

[9] ZE Y, HANSEN N, CHEN Y, et al. Visual reinforcement learning with self-supervised 3D representations[J]. IEEE Robotics and Automation Letters, 2023, 8(5): 2890–2897.

[10] LEE M A, ZHU Y, ZACHARES P, et al. Making sense of vision and touch: Learning multimodal representations for contact-rich tasks[J]. IEEE Transactions on Robotics, 2020, 36(3): 582-596.

[11] KIM D J, JO H J, SONG J B. Tidyup tasks using trajectorybased imitation learning [C]. 2021 21st International Conference on Control, Automation and Systems (ICCAS). Jeju，Korea，Republic of，2021：496-499，https://doi.org/10.23919/ICCAS52745.2021.9649826.

[12] JONSCHKOWSKI R, BROCK O. Learning state representations with robotic priors[J]. Autonomous Robots, 2015, 39(3): 407–428.

[13] ZHANG F, LEITNER J, MILFORD M, et al. Towards Vision Based Deep Reinforcement Learning for Robotic Motion Control[J]. Computer Science，2015，DOI: 10.48550/arXiv.1511.03791

[14] JAMES S, JOHNS E. 3D simulation for robot arm control with deep Q-learning[J]. 2016, DOI:10.48550/arXiv.

1609.03759.

[15] ZENG A, SONG S, LEE J, et al. TossingBot: Learning to Throw Arbitrary Objects With Residual Physics[J]. IEEE Transactions on Robotics, 2020, 36(4): 1307–1319.

[16] FRANCESCHETTI A, TOSELLO E, CASTAMAN N, et al. Robotic arm control and task training through deep reinforcement learning[C]. International Conference on Intelligent Autonomous Systems. Springer，Cham，2022，DOI：10.1007/978-3-030-95892-3_41

[17] PENG G，YANG J，LI X，et al. Deep Reinforcement Learning With a Stage Incentive Mechanism of Dense Reward for Robotic Trajectory Planning[J]. IEEE Transactions on Systems, Man, and Cybernetics, 2023, 53(6): 3566-3573.

[18] LI Z, HU X, ZHANG Y, et al. Task-Oriented Reinforcement Learning with Interest State Representation [C]. 2024 International Conference on Advanced Robotics and Mechatronics (ICARM). Tokyo, Japan, 2024, pp. 721-728, DOI: 10.1109/ICARM62033.2024.10715850.

[19] YANG S, ZHANG W, LU W, et al. Learning Actions from Human Demonstration Video for Robotic Manipulation[C].2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)，IEEE，2020，DOI：10.1109/IROS40897.2019.8968278.

[20] JIA Z, LIN M, CHEN Z, et al. Vision based Robot Manipulation Learning via Human Demonstrations[J]. 2020, DOI: 10.48550/arXiv.2003.00385.

[21] CHANG P，LUO R，DOROSTIAN M, et al. A Shared Control Method for Collaborative HumanRobot Plug Task[J]. IEEE Robotics and Automation Letters, 2021, 6 (4): 7429–7436.

[22] REY J, KRONANDER K, FARSHIDIAN F, et al. Learning motions from demonstrations and rewards with time-invariant dynamical systems based policies. Autonomous Robots, 2018, 42(1): 45–64 .

[23] GAO Xiao. Research of Motion Planning and Compliant Control for Robot Manipulators Based on Imitation Learning [D]. Wuhan: Wuhan University, 2021.[高霄. 基于模仿学习的机械臂运动规划与柔顺控制研究[D]. 武汉：武汉大学，2021.]

作者简介：

周福杰(1998-)，男，安徽六安人，硕士研究生，研究方向：深度强化学习、机器人控制与决策，E-mail：1749762053@qq.com;

+胡祥涛(1981-)，男，安徽安庆人，教授，博士，博士生导师，研究方向：机器学习、数字孪生技术、机器人化智能制造，通讯作者，E-mail：hust_hoo@ahu.edu.cn；

李子怡(2000-)，男，安徽淮北人，硕士研究生，研究方向：强化学习、机器人控制与决策等，E-mail：1027431187@qq.com；

韦治宏(2001-)，男，安徽阜阳人，硕士研究生，研究方向：强化学习，E-mail：2252493510@qq.com。